

Rédaction de documents en R Markdown

Sophie Baillargeon, Université Laval

2018-02-14

Table des matières

Introduction	1
Logiciels de type WYSIWYM	2
Recherche reproductible et programmation lettrée	3
Sweave et knitr	4
R Markdown	5
Création d'un document R Markdown en RSudio	5
Compilation de fichier R Markdown en RStudio	7
Blocs de code R dans un fichier R Markdown	8
Commande R intégrée à un bout de texte	8
Intégration de figures à un fichier R Markdown	9
Intégration de tableaux à un fichier R Markdown	11
Trucs divers dans l'édition de documents R Markdown	11
Références	12

Introduction

Pour rédiger un document destiné à être publié (rapport, article, mémoire, thèse, etc.), plusieurs outils s'offrent à nous. En science, deux des outils les plus utilisés pour la création de documents sont :

- Word,
- LaTeX.

Voyons d'abord la distinction entre ces deux outils.

Word :

En Word, **le contenu et la mise en forme du document ne font qu'un**. Le fichier dans lequel nous travaillons pour créer le document est directement le document final.

En anglais, on dit que ce logiciel est de type **WYSIWYG**. Cet acronyme signifie *What You See Is What You Get*.

LaTeX :

Avec LaTeX, **le contenu est dissocié de la mise en forme**. Le fichier dans lequel nous travaillons, portant l'extension .tex, n'est pas le document final. Nous devons compiler le fichier .tex afin d'obtenir ce document final (.pdf ou autre). Le fichier .tex contient le texte du document, soit le contenu, mais aussi des tags pour la mise en forme. Par exemple, il y a des tags pour changer de sections, modifier la police de caractères, inclure une liste, un tableau ou une figure, etc.

En anglais, on dit que ce logiciel est de type **WYSIWYM**. Cet acronyme signifie *What You See Is What You Mean*.

Logiciels de type WYSIWYM

Avec les logiciels de type WYSIWYM, un document se crée en :

- éditant un fichier source, puis en
- compilant le fichier source pour obtenir le document final.




FIGURE 1 – Production de documents avec un logiciel de type WYSIWYM

Utilisation de LaTeX :

En fait, LaTeX est un **langage de composition de documents**. Afin de créer un document en utilisant ce langage, nous avons besoin de :

- un **éditeur LaTeX** :
 - TeXstudio (multiplateforme, gratuit) : <http://texstudio.sourceforge.net/>,
 - ou autre : https://en.wikipedia.org/wiki/Comparison_of_TeX_editors.
- un **compilateur LaTeX** :
 - MiKTeX (Windows, gratuit) : <http://miktex.org/>,
 - ou autre : https://fr.sharelatex.com/learn/Choosing_a_LaTeX_Compiler.

Markdown :

Markdown est un langage simple de composition de documents en format HTML (interprétable par un navigateur web). Il s'agit donc d'un outil permettant de créer des pages web sans avoir à connaître le langage HTML.




FIGURE 2 – Production de documents avec Markdown

Markdown offre moins de possibilités de mise en forme que LaTeX, mais il est plus simple à apprendre et utiliser.

Recherche reproductible et programmation lettrée

Recherche reproductible :

La recherche reproductible (en anglais *reproducible research*) est un courant en recherche qui prône le partage de données et de programmes informatiques en accompagnement de publications scientifiques faisant intervenir de l'analyse de données. Le but de ce partage est de **permettre à tout lecteur de reproduire par lui-même les résultats publiés**. Ainsi, la publication est plus facile à comprendre, les résultats peuvent être vérifiés et la poursuite des travaux est facilitée. La recherche devrait en ressortir accélérée.

Programmation lettrée :

La programmation lettrée (en anglais *literate programming*) est une approche de programmation dans laquelle le code n'est pas simplement documenté par quelques commentaires. Du texte expliquant ce que le code doit produire est entrelacé avec le code, à l'intérieur du même document. Pour que ce texte explicatif soit clair, il devrait pouvoir inclure toutes sortes d'éléments usuels dans des documents textuels, tels que des listes, des tableaux, des images, etc. Il n'est pas facile d'inclure de tels éléments dans des commentaires à l'intérieur d'un script. En programmation lettrée, le document de travail devient donc principalement un document texte, mais celui-ci contient des bouts de code bien identifiés en étant encadrés par des tags. Et il existe une façon de soumettre facilement ce code.

En fin de compte, le principe de programmation lettrée devient en quelque sorte de la rédaction de **documents combinant du texte et des bouts de code informatique**. Il s'agit d'une façon de mettre en oeuvre de la recherche reproductible. C'est aussi une façon productive de rédiger des documents devant contenir des bouts de code et/ou des sorties informatiques. En effet, le document contenant le « programme lettré » peut être compilé afin de générer un autre document qui lui peut afficher, pour chaque bout de code :

- seulement le code ou
- le code et les sorties informatiques qu'il produit lorsqu'il est soumis (par exemple un affichage texte comme dans une console, ou encore un graphique) ou
- seulement les sorties informatiques ou
- rien du tout.

Cette approche est très utile pour rédiger un **guide d'utilisation d'un langage informatique**. Par exemple, j'ai utilisé R Markdown, un outil de programmation lettrée, pour rédiger le document que vous êtes en train de lire, ainsi que toutes les autres notes du cours STT-4230/STT-6230 R pour scientifique.

Une autre utilité de cette approche est la rédaction facilitée de **rapport d'analyse de données**. Nous nous intéressons ici à une analyse de données effectuée en R, mais la programmation lettrée pourrait s'appliquer avec n'importe quel logiciel d'analyse de données fonctionnant avec du code informatique (plutôt que seulement avec une interface utilisateur composée de menus et de boutons cliquables). Avec un outil de programmation lettrée, il est facile de rédiger un rapport contenant du texte explicatif et des résultats d'analyse sous forme de sorties informatiques. Nul besoin de copier/coller des valeurs dans un tableau, ou d'insérer manuellement un graphique. Tout est fait automatiquement lors de la compilation du document. Ainsi, si les données changent ou si nous décidons de modifier une analyse, nous n'avons pas besoin d'effectuer manuellement les mises à jour dans les résultats. Nous avons seulement besoin de mettre à jour le code et de recompiler le rapport. Cette approche peut nous permettre de sauver beaucoup de temps et minimise les risques d'erreur dans les résultats rapportés.

Sweave et knitr

En R, il est possible d'effectuer de la programmation lettrée avec la fonction **Sweave** (du package **utils**) ou avec le package **knitr**.

Ces packages permettent de créer des publications qui contiennent des **bouts de code et/ou des sorties R**, sans faire de copier/coller à partir d'un programme R ou de la console R.

Sweave :

Sweave est le premier outil à avoir été développé pour faire de la programmation lettrée en R. Il permet d'intégrer du code R à des **documents LaTeX**.

Les tags encadrant les bouts de code R dans le fichier source acceptent des options permettant de contrôler :

- ce qui doit être compilé ou non,
- ce qui doit être affiché ou non (code, sorties, figures),
- la mise en forme de l'affichage.

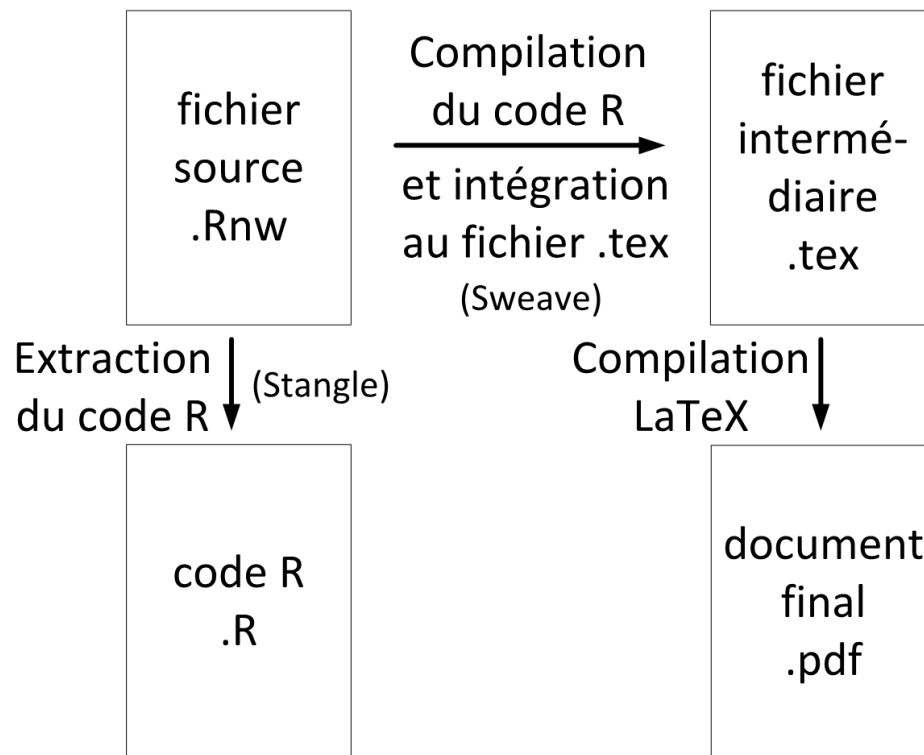


FIGURE 3 – Schéma de compilation avec Sweave

knitr :

knitr est une alternative à **Sweave**, plus récente et maintenant plus utilisée. Les options de mise en forme par défaut des éléments R intégrés au fichier LaTeX ne sont pas les mêmes avec **knitr** qu'avec **Sweave**.

De plus, **knitr** permet d'intégrer des éléments R à d'autres types de fichiers que LaTeX, notamment à des fichiers Markdown. C'est ce qu'on appelle le **R Markdown**.

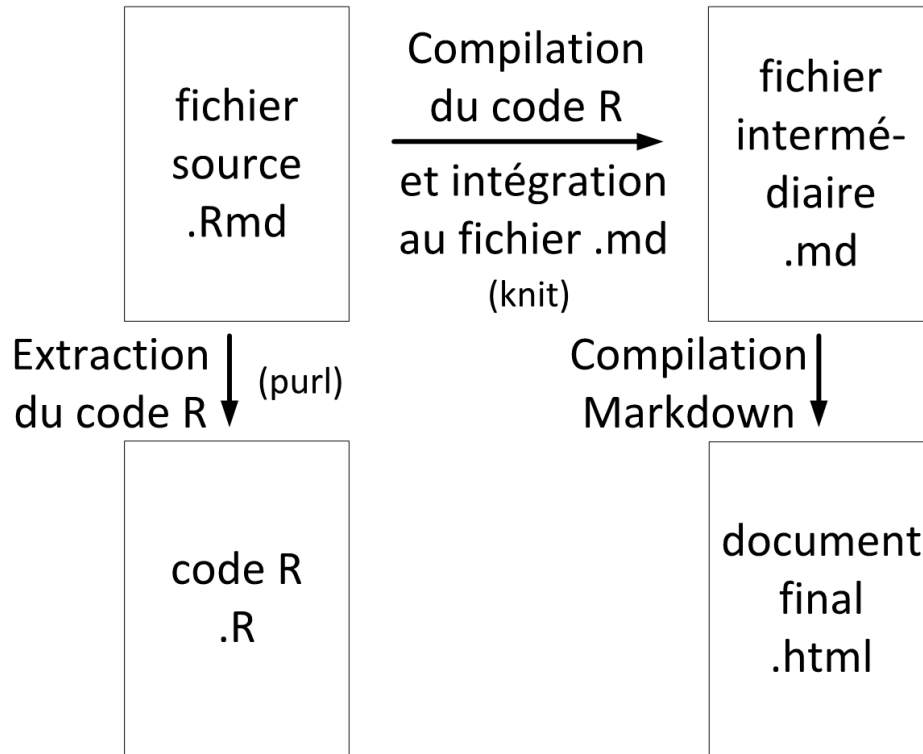


FIGURE 4 – Schéma de compilation avec R Markdown

R Markdown

Création d'un document R Markdown en RSudio

Le meilleur outil pour rédiger et compiler des documents R Markdown est RStudio. Les instructions suivantes se rapportent à RStudio.

Nous pouvons créer un nouveau document R Markdown (extension .Rmd) par le menu :

- « File > New File > R Markdown... »

Une fenêtre s'ouvre alors. Nous devons spécifier quelques informations à propos de notre fichier.

1. Le menu de gauche sert à indiquer quel **type de produit final** nous voulons créer :
 - un document,
 - une présentation,
 - un document avec composantes interactives (Shiny) ou
 - un document suivant un certain modèle prédéfini (p. ex. document GitHub ou vignette de package).
2. Dans la partie de droite de la fenêtre, nous spécifions :
 - le titre du document,
 - le nom de l'auteur,
 - le format préféré pour le fichier final.

En cliquant sur OK, un fichier est créé. Il devrait avoir l'allure suivante :




FIGURE 5 – Exemple de nouveau document R Markdown

Il ne reste plus qu'à :

1. **enregistrer** le fichier,
2. **éditer** le fichier en respectant :
 - la syntaxe Markdown et
 - les noms d'options de **knitr** pour les bouts de code R,
3. **compiler** le fichier.

Formats du document final :

Bien qu'à l'origine Markdown ait été créé pour générer des documents HTML, nous pouvons maintenant l'utiliser pour générer des documents dans d'autres formats. Avec RStudio, il est facile de compiler un fichier Markdown ou R Markdown notamment dans les formats suivants, grâce à Pandoc (intégré à RStudio) :

- HTML,
- PDF (à la condition d'avoir un compilateur LaTeX),
- Word.

Entête d'un fichier R Markdown :

Un fichier R Markdown débute presque toujours par un entête entre deux lignes contenant uniquement :

Cet entête peut contenir des informations à inclure dans l'entête du document final, tel que :

- le titre du document,
- le nom de l'auteur,
- la date de publication du document.

Cet entête peut aussi contenir des informations spécifiant le format et des options de mise en forme du document final. Ces options varient en fonction du format de sortie. Le site web suivant fournit de l'information sur les options possibles : <http://rmarkdown.rstudio.com/formats.html>

Syntaxe Markdown

La syntaxe Markdown utilisée par R Markdown est la version Pandoc, documentée sur le site web suivant : http://rmarkdown.rstudio.com/authoring_pandoc_markdown.html

Les éléments de base de cette syntaxe sont bien présentés sur la page web suivante : http://rmarkdown.rstudio.com/authoring_basics.html

Compilation de fichier R Markdown en RStudio

Les deux étapes de compilation s'effectuent en cliquant sur un seul bouton, dans la barre en haut du fichier :

- bouton **Knit** (petite pelote de laine avec aiguilles à tricoter).

La petite flèche vers le bas semblable à ▼ à côté du bouton **Knit** permet de sélectionner le format du fichier final. Le symbole de roue d'engrenage permet d'ouvrir un menu pour modifier les paramètres de la compilation.

Peu importe le format final de la sortie, la compilation cache toujours en fait plusieurs étapes intermédiaires dont :

- la compilation du code R dans une nouvelle session R (pas dans celle déjà ouverte en RStudio) ;
- l'intégration des résultats de cette compilation à un document
 - Markdown (.md) pour un résultat final en HTML,
 - LaTeX (.tex) pour un résultat final en PDF,
 - Word ;
- la compilation de ce document (sauf pour le format Word) pour produire le fichier final.

Blocs de code R dans un fichier R Markdown

Dans un fichier R Markdown, le code R doit être encadré par le tag d'ouverture composé de trois apostrophes inversées suivies de `{r}` et le tag de fermeture composé de trois apostrophes inversées. Entre les accolades et après le `r`, nous pouvons ajouter un nom et des options de blocs de code R, séparées par des virgules. Nommer les blocs de code est utile pour se retrouver plus facilement dans un document contenant plusieurs blocs de code. Voici un exemple de bloc de code nommé, mais pour lequel aucune option n'a été modifiée.

```
```{r chunk}
a <- 1 + 1
a
```
```

Sans modifier les options par défaut du bloc de code, le code et les sorties produites seront intégrés au document comme suit.

```
a <- 1 + 1
a

## [1] 2
```

Options de blocs de code R en R Markdown :

Les options de blocs de code R les plus utiles sont les suivantes :

- `eval` (TRUE par défaut, ou FALSE) : détermine si le code R doit être évalué ou non,
- `echo` (TRUE par défaut, ou FALSE) : détermine si le code R doit être affiché ou non,
- `results` ('markup' par défaut, ou 'hide' ou 'hold' ou 'asis') : détermine comment les sorties doivent être affichées,
- `error` (FALSE par défaut, ou TRUE) : détermine si les messages d'erreur doivent être affichés.
- `warning` (TRUE par défaut, ou FALSE) : détermine si les messages d'avertissement doivent être affichés.

Il existe bien d'autres options, résumées dans le document suivant :

<https://www.rstudio.com/wp-content/uploads/2015/03/rmarkdown-reference.pdf>

Voici un exemple de bout de code R avec options :

```
```{r R.options = list(width = 50), comment = ""}
b <- c(1:10, rep(11, 20))
b
```
```

Voici ce que ce bout de code inclut dans le document final.

```
b <- c(1:10, rep(11, 20))
b

[1] 1 2 3 4 5 6 7 8 9 10 11 11 11 11 11
[16] 11 11 11 11 11 11 11 11 11 11 11 11 11 11 11
```

Commande R intégrée à un bout de texte

Il est aussi possible d'inclure une commande R retournant un simple vecteur dans un bout de texte. Seulement la sortie produite par la commande R sera affichée. Il faut encadrer la commande du tag ouvrant composé d'une seule apostrophe inversée suivie de `r` et du tag fermant composé uniquement d'une apostrophe inversée.

Par exemple, la phrase suivante dans un document R Markdown :

```
La division de 5 par 3 donne le résultat `r 5/3`.
```


produit le résultat suivant :

La division de 5 par 3 donne le résultat 1.6666667.

Intégration de figures à un fichier R Markdown

À partir d'un fichier image :

Il est possible d'intégrer une figure provenant d'un fichier image en utilisant la syntaxe Markdown suivante :

- fichier local : ``
- fichier provenant du web : ``

Note : Seuls les chemins relatifs à l'emplacement du fichier source R Markdown sont acceptés. Alors le fichier image local doit être dans le même répertoire que le fichier `.Rmd` ou dans un sous-répertoire de ce répertoire.

Si nous ajoutons du texte entre les crochets, celui-ci devient le titre de la figure.

Par exemple, la commande Markdown suivante :

```
![Exemple de figure](fig/WYSIWYM.png)
```

produit le résultat suivant :




FIGURE 6 – Exemple de figure

Il n'est cependant pas possible de contrôler la taille de l'image avec cette syntaxe. Si nous travaillons dans un document R Markdown plutôt que simplement Markdown, il existe une autre façon d'intégrer une figure provenant d'un fichier image qui permet un meilleur contrôle sur la figure produite. Pour ce faire, il faut créer un bloc de code R dans lequel la fonction `include_graphic` du package `knitr` est appelée. En voici un exemple suivi du résultat produit.

```
```{r out.width = "70%", fig.align = 'center', fig.cap = "Autre exemple de figure"}
knitr::include_graphics("fig/WYSIWYM.png")
```
```




FIGURE 7 – Autre exemple de figure

Les options `out.height` et `out.width` permettent de contrôler les dimensions de la figure.

À partir d'un bloc de code R qui génère un graphique :

Nous pouvons aussi intégrer une figure à un fichier R Markdown à l'aide d'un bloc de code R qui génère un graphique. Voici un exemple suivi du résultat produit.

```

```{r fig.height = 3.5, out.width = "100%", fig.cap = "Encore un exemple de figure"}
plot(cars, main = "Relation entre la vitesse et la distance de freinage de voitures")
```

```




FIGURE 8 – Encore un exemple de figure

Lorsque la figure est créée par le code R, nous pouvons contrôler les dimensions de la fenêtre graphique avec les options `fig.height` et `fig.width`. Malgré tout, les options `out.height` et `out.width` continuent de contrôler la dimension de la figure dans le document final.

Intégration de tableaux à un fichier R Markdown

Il existe une syntaxe Markdown pour créer des tableaux. Par exemple, le code Markdown suivant :

```
Droite	Gauche	Défaut	Centré
12	12	12	12
123	123	123	123
1	1	1	1
```

produit le tableau suivant :

| Droite | Gauche | Défaut | Centré |
|--------|--------|--------|--------|
| 12 | 12 | 12 | 12 |
| 123 | 123 | 123 | 123 |
| 1 | 1 | 1 | 1 |

Aussi, la fonction `kable` du package `knitr` permet d'intégrer un data frame R sous forme de tableau dans un document produit avec R Markdown. Voici un exemple suivi du résultat produit.

```
```{r results = 'asis'}  
knitr::kable(head(cars, 3), caption = "Exemple de tableau")
```
```

TABLE 2: Exemple de tableau

| speed | dist |
|-------|------|
| 4 | 2 |
| 4 | 10 |
| 7 | 4 |

Notons que d'autres fonctions permettent de formater une matrice ou un data frame R pour créer un tableau dans un document rédigé en R Markdown. Quelques-unes sont mentionnées sur la page web suivante : http://kbroman.org/knitr_knutshell/pages/figs_tables.html. La mise en forme du tableau obtenu diffère légèrement d'une fonction à l'autre.

Trucs divers dans l'édition de documents R Markdown

- Pour faire un retour de chariot sans changer de paragraphe : insérer **deux caractères espace** à la fin d'une ligne, avant le retour de chariot.
- Pour insérer une ligne vide dans le document final : insérer une ligne contenant uniquement le caractère « ` ` », qui représente un espace en HTML.
- Pour insérer un commentaire (texte n'apparaissant pas dans le document final) : utiliser les tags html pour des commentaires, soit

```
<!-- commentaire ici (possiblement sur plusieurs lignes) -->
```

- Raccourci clavier pour insérer un bloc de code R dans un fichier R Markdown en RStudio : Alt + I (sous Windows).

- Pour modifier les options par défaut pour les blocs de code R :
insérer la ligne suivante (avec les options désirées) au tout début du fichier .Rmd (juste en dessous de l'entête)

```
`r knitr::opts_chunk$set(echo = FALSE, results = 'hide')`
```

- Pour avoir des noms automatiques d'éléments en français lors de la création d'un document final au format PDF (par exemple le titre de la table des matières) :
ajouter dans l'entête les lignes suivantes :

header-includes:

```
- \usepackage[french]{babel}
```

Références

Recherche reproductible : https://en.wikipedia.org/wiki/Reproducibility#Reproducible_research

Programmation lettrée : https://fr.wikipedia.org/wiki/Programmation_lettr%C3%A9e

Documentation de R Markdown :

- <http://rmarkdown.rstudio.com/>
- <http://www.rstudio.com/wp-content/uploads/2016/03/rmarkdown-cheatsheet-2.0.pdf>

Options de blocs de code R :

- <https://www.rstudio.com/wp-content/uploads/2015/03/rmarkdown-reference.pdf>
- <https://yihui.name/knitr/options/>