

Présentation de R

Sophie Baillargeon

2019-01-09

Qu'est-ce que R ?

- ▶ un **environnement** et un **langage de programmation** pour effectuer des *calculs statistiques* et créer des *graphiques*;
- ▶ un **logiciel libre** : logiciel *gratuit*, distribué avec son *code source*, il peut être *étudié, modifié et partagé librement*;
- ▶ un logiciel formé des composantes suivantes :
 - ▶ **R de base** (fonctions statistiques et graphiques standards),
 - ▶ **extensions appelées packages** (collections de nouvelles fonctions créées par des utilisateurs).

Que fait-on avec R ?

Typiquement, on utilise d'abord R pour faire de l'**analyse statistique de données**. On réalise donc en R les tâches suivantes :

- ▶ **manipuler des données**;
- ▶ appeler des fonctions préexistantes de **calculs statistiques** (estimation de statistiques, ajustement de modèle, etc.);
- ▶ produire des **graphiques**;
- ▶ rédiger des **rapports d'analyse** de données.

Lorsqu'on a besoin d'aller plus loin

Plusieurs utilisateurs de R doivent un jour **développer leurs propres fonctions** de calcul statistique. On peut devenir un développeur lorsque :

- ▶ on a besoin de faire la même analyse à plusieurs reprises (**automatiser des calculs**);
- ▶ on souhaite **améliorer les implantations existantes** d'une méthode de calcul;
- ▶ on cherche à **développer de nouvelles méthodes** de calcul.

On passe d'utilisateur de R à développeur R souvent sans même s'en rendre compte.

Historique de R

1990 - Au Département de statistique de l'**Université d'Auckland** en Nouvelle-Zélande, **Ross Ihaka** et **Robert Gentleman** (alors en année sabbatique de l'Université de Waterloo au Canada) ont l'idée de créer un nouveau logiciel statistique pour tester quelques idées dans leurs **travaux de recherche**.

1992 - Le langage est nommé **R**, car il s'agit de la première lettre des prénoms des deux créateurs (maintenant tous deux professeurs à l'Université d'Auckland), et parce qu'il est décidé que le langage utilisera la syntaxe du **langage S** développé dans les Bell Laboratories par John Chambers et collaborateurs.

1994 - Une version initiale du logiciel est utilisée pour **donner des cours** d'introduction à la statistique et elle est **distribuée sur internet**. Il est décidé que R sera un **logiciel libre**.

Créateurs

Robert Gentleman et Ross Ihaka dans les années 90 :



Source : <https://www.stat.auckland.ac.nz/~ihaka/downloads/Otago.pdf>

Historique de R - suite

1996 - Martin Mächler de l'École polytechnique fédérale de Zurich en Suisse se joint à l'équipe des R & R pour développer R, qui connaît de plus en plus de succès. Malgré tout, bien vite trois personnes ne suffisent plus pour gérer le flot constant de courriels reçus d'utilisateurs.

1997 - Le CRAN est créé par Kurt Hornik et Friedrich Leisch à l'Université technique de Vienne en Autriche. Il s'agit d'un dépôt informatique pour les contributions des utilisateurs (packages). Peu après, le « **R core** », soit le noyau de développeurs de R, est formé.

2000 - La première version officielle de R est publiée à une date particulière : le 29 février 2000!

Organisation de R

Les membres du « R core » sont typiquement des chercheurs en calcul statistique. Ils travaillent pour différentes organisations, typiquement des universités, aux quatre coins du monde.

- ▶ Depuis 2002, la **fondation R** amasse des dons et les utilisent pour maintenir des infrastructures et pour commanditer quelques travaux de développement.
- ▶ Des **conférences** sont organisées et réunissent les développeurs de R ainsi que des utilisateurs de R :
<https://www.r-project.org/conferences.html>
- ▶ R a aussi sa **revue scientifique**, The R journal :
<https://journal.r-project.org>

Développement de R

- ▶ R est en **constant développement**. Il est actuellement mis à jour 4 à 6 fois par année. La version courante de R est téléchargeable sur le site web du projet R : <https://www.r-project.org>.
- ▶ Le **nombre de packages sur le CRAN** croît de façon exponentielle (<http://blog.revolutionanalytics.com/2017/01/cran-10000.html>).
- ▶ Il y a maintenant **plus de 13 500 packages** sur le CRAN (<https://cran.r-project.org/web/packages/>) et **plus de 1500 packages** sur Bioconductor (<http://www.bioconductor.org/>), un dépôt informatique pour des contributions en R spécialisées en bio-informatique. Plusieurs de ces packages sont eux aussi en constant développement.


Popularité de R

- ▶ De plus en plus de gens l'utilisent.
- ▶ Beaucoup de gens en parlent sur internet.
- ▶ Savoir programmer en R est une compétence fréquemment demandée pour des emplois en statistique/science des données.

Quelques statistiques sur la popularité grandissante de R :

- ▶ <http://blog.revolutionanalytics.com/popularity/>
- ▶ <http://r4stats.com/articles/popularity>

Augmentation de nombre de questions relatives à R sur Stack Overflow



Source : <https://insights.stackoverflow.com/trends>, 9 janvier 2019.

Forces de R

- ▶ logiciel libre : a l'avantage d'être **gratuit**, donc de favoriser la **recherche reproductible**;
- ▶ **langage interprété** : langage plus proche de notre langage que du langage machine, donc plus simple et direct que, par exemple, du C ou du C++;
- ▶ **facilite le partage et la réutilisation de code** grâce au système des packages;
- ▶ communauté active de développeurs et d'utilisateurs :
 - ▶ R **évolue vite**, ses bogues sont identifiés et corrigés rapidement;
 - ▶ on retrouve **beaucoup d'information** concernant la programmation en R sur internet;
 - ▶ le **nombre de packages R est toujours grandissant**, ainsi de nouvelles fonctionnalités sont fréquemment ajoutées à R.

Limites de R

Les caractéristiques de R sont particulièrement adaptées au monde de la recherche et de l'enseignement. Il est donc très utilisé dans les universités. Par contre, il comporte les limites suivantes :

- ▶ logiciel libre : certaines organisations **préfèrent utiliser un logiciel commercial**;
- ▶ langage interprété : **R est parfois lent** pour réaliser certains calculs;
- ▶ gestion de la mémoire : **le R de base est plus ou moins adapté à la manipulation de données volumineuses** (mais de plus en plus de packages sont créés pour contrer ce problème).

Logiciel libre versus commercial

Certains préfèrent utiliser un logiciel commercial, car :

- ▶ Un logiciel libre n'offre **aucune garantie officielle quant à la validité de ses résultats**.
 - ▶ Cependant, Keeling et Pavur (2007) arrivent à la conclusion que les résultats obtenus en R pour les analyses statistiques les plus courantes sont tout aussi exacts que ceux obtenus d'autres logiciels statistiques.
- ▶ Un logiciel libre n'offre **pas de soutien technique**.
 - ▶ Cependant, plusieurs sites de questions/réponses (ex. <https://stackoverflow.com/>) ainsi que des listes courriel existent. On obtient rapidement une réponse d'autres utilisateurs lorsque l'on y soumet une question.

R dans les entreprises ?

- ▶ Selon certains (voir le billet de blogue intitulé « [Six Reasons to Learn R for Business](#) »), R possède les avantages suivants pour les entreprises, qui compensent largement pour sa courbe d'apprentissage :
 - ▶ **grandes capacités en science de données** :
 - ▶ interactivité,
 - ▶ outils analytiques avancés (accès à des méthodes statistiques nouvellement développées),
 - ▶ communications facilitées par les outils de production de graphiques, rapports et applications web interactives;
 - ▶ **faible coût** (*intéressant pour les petites entreprises*);
 - ▶ **croissante rapide**.
- ▶ De plus en plus de **compagnies l'utilisent** (un répertoire Github intitulé « [Companies, Officials and NGO Using R](#) »).

Références intressantes pour en savoir plus

- ▶ Fox, J. (2009). Aspects of the Social Organization and Trajectory of the R Project. *The R Journal*. Vol. 1 (2), pp. 5-13.
http://journal.r-project.org/archive/2009-2/RJournal_2009-2_Fox.pdf
- ▶ Ihaka, R. (2011, April 20). The R Project: A Brief History and Thoughts About the Future [Présentation].
<https://www.stat.auckland.ac.nz/~ihaka/downloads/Otago.pdf>
- ▶ Keeling, K. B. et Pavur, R. J. (2007). A comparative study of the reliability of nine statistical software packages. *Computational Statistics & Data Analysis*. Vol. 51, pp. 3811-3831.
- ▶ Peng, R. (2018, 12 juillet). Teaching R to New Users - From tapply to the Tidyverse [Billet de blogue].
<https://simplystatistics.org/2018/07/12/use-r-keynote-2018/>
- ▶ Thieme, N. (2018). R generation. *Significance magazine*, Vol. 15 (4), pp. 14-19.