Structures de contrôle en R

Sophie Baillargeon, Université Laval 2019-03-10

Table des matières

Alternatives	2
Écriture générale	2
Écriture condensée	
Distinction entre une structure if else et la fonction ifelse	
Boucles	5
Boucles for	5
Enregistrement des résultats dans une boucle	7
Affichage de résultats dans une boucle	
Boucles while ou repeat	9
Imbriquer des boucles	10
Mots-clés break et next	10
Interruption de l'exécution d'une boucle	
Éviter les boucles	
Calcul vectoriel versus boucle	
Fonction de la famille des apply versus boucle	
Références	12

La matière vue jusqu'à maintenant dans le cours traitait principalement de l'utilisation du logiciel R dans le but de faire de la manipulation ou de l'analyse de données, incluant la production de graphique. Cette utilisation passe par la soumission de commandes dans la console de R. En fait, souvent plus d'une commande est nécessaire pour produire le résultat escompté. Plutôt que de soumettre une après l'autre les commandes dans la console, il est alors préférable d'écrire un petit programme (en d'autres mots un bloc de code). Les commandes sont alors plutôt appelées instructions. Lorsque le programme est soumis, les instructions qui le composent sont exécutées séquentiellement, c'est-à-dire l'une après l'autre, en respectant leur ordre d'apparition dans le programme.

Comme pratiquement tout langage de programmation, R offre des **structures de contrôles** (aussi appelées séquencements). Les structures de contrôle sont des instructions particulières qui contrôlent l'ordre dans lequel les autres instructions du programme informatique sont exécutées.

Ainsi, il est possible de demander à R d'exécuter les instructions d'un programme autrement que séquentiellement. Les deux structures de contrôle de base sont présentées ici :

- les alternatives : structures conditionnelles,
- les boucles : structures itératives.

Alternatives

Les alternatives ont pour but d'exécuter des instructions seulement si une certaine condition est satisfaite.

Écriture générale

```
if (condition) {
  instructions # exécutées si condition est TRUE
} else {
  instructions # exécutées si condition est FALSE
}
```

Les mots-clés pour écrire des alternatives en R sont if et else. En fait, il est possible d'avoir un if sans else.

Un if doit être suivi d'une paire de parenthèses dans laquelle est inséré une instruction R retournant un seul TRUE ou un seul FALSE. C'est la condition de l'alternative. Ensuite viennent la ou les instructions à exécuter si la condition est vraie (c'est-à-dire si l'instruction condition produit le résultat TRUE). S'il y a plus d'une instruction à exécuter, les accolades sont nécessaires pour les encadrer. Pour une seule instruction, les accolades sont optionnelles.

Voici un exemple:

```
# Simulation du lancer d'une pièce de monnaie
lancer <- sample(x = c("Pile", "Face"), size = 1)

# Structure qui affiche ou non un message,
# en fonction du résultat du lancer

if (lancer == "Pile")  # sans accolades
    print("Je gagne!")

# ou encore

if (lancer == "Pile") { # avec accolades
    print("Je gagne!")
}</pre>
```

Lorsqu'il y a des instructions à exécuter si la condition est fausse, il faut ajouter un else à l'alternative, suivi des instructions en question. Dans ce cas, il est considéré comme une bonne pratique de toujours encadrer les instructions d'accolades (sauf si l'écriture condensée, qui sera présentée plus loin, est utilisée), même s'il n'y a qu'une seule instruction, de façon à retrouver le mot-clé else précédé de } et suivi de { .

Voici un exemple:

```
if (lancer == "Pile") {
  print("Je gagne!")
} else {
  print("Je perds...")
}
```

Plusieurs if...else peuvent être imbriqués.

Voici un exemple :

```
# Programme qui calcule des statistiques descriptives simples,
# selon le type des éléments du vecteur sur lequel le calcul est fait
x <- iris$Sepal.Length</pre>
```

```
if (is.numeric(x)) {
  min \leftarrow min(x)
  moy \leftarrow mean(x)
  max \leftarrow max(x)
  stats <- c(min = min, moy = moy, max = max)</pre>
} else if (is.character(x) || is.factor(x)) {
  stats <- table(x)</pre>
} else {
  stats <- NA
stats
##
         min
                   moy
                             max
## 4.300000 5.843333 7.900000
# Faisons rouler les instructions de nouveau,
# après avoir redéfini le vecteur x.
x <- iris$Species
if (is.numeric(x)) {
  min \leftarrow min(x)
  moy \leftarrow mean(x)
  max \leftarrow max(x)
  stats <- c(min = min, moy = moy, max = max)
} else if (is.character(x) | is.factor(x)) {
  stats <- table(x)
} else {
  stats <- NA
}
stats
## x
##
       setosa versicolor virginica
##
                         50
```

Il serait pratique de créer une fonction à partir de ce bout de code. Nous le ferons dans les notes sur les fonctions en R.

Remarque: La fonction switch est parfois utile pour remplacer plusieurs if ... else imbriqués, mais cette fonction ne sera pas étudiée ici.

Écriture condensée

Lorsque, dans chaque branche d'une alternative, il n'y a qu'une seule instruction courte servant à créer un objet, l'écriture condensée suivante peut être pratique :

```
nom <- if (condition) instruction else instruction
```

Cette écriture est recommandée seulement si elle rend le code plus lisible pour des alternatives très simples.

Voici un exemple:

```
message <- if (lancer == "Pile") "Je gagne!" else "Je perds..."</pre>
```

Distinction entre une structure if ... else et la fonction ifelse

Sous sa forme condensée, une structure if ... else fait penser à un appel à la fonction ifelse. Quelles sont les différences entre les deux?

Premièrement, la condition dans une structure if ... else doit être une instruction qui retourne un seul TRUE ou un seul FALSE, pas un vecteur logique de longueur supérieure à 1. Si la condition est un vecteur logique de longueur supérieure à 1, seul le premier élément est utilisé et un avertissement est affiché comme dans l'exemple suivant :

```
x <- 1:10  
xmodif <- if(x > 2.5 & x < 7.5) 5 else x  
## Warning in if (x > 2.5 & x < 7.5) 5 else x: the condition has length > 1  
## and only the first element will be used  
xmodif
```

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

Si nous avions utilisé l'opérateur logique && au lieu de &, nous n'aurions pas obtenu cet avertissement, mais exactement le même résultat aurait été obtenu.

```
xmodif <- if(x > 2.5 \&\& x < 7.5) 5 else x xmodif
```

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

Les opérateurs logiques && et | | sont utiles pour écrire une condition d'un if, car elles assurent la production d'une seule valeur logique.

Cependant, dans cet exemple, la structure de contrôle if ... else n'est probablement pas ce que nous voulions utiliser. Si notre but est de vérifier pour chaque élément de x si la valeur est comprise entre 2.5 et 7.5, si c'est le cas retourner la valeur 5, sinon retourner l'élément de x inchangé, alors c'est la fonction ifelse que nous devrions utiliser.

```
xmodif <- ifelse(test = x > 2.5 \& x < 7.5, yes = 5, no = x) xmodif
```

```
## [1] 1 2 5 5 5 5 5 8 9 10
```

ifelse est une fonction qui agit de façon vectorielle. Elle teste une condition sur tous les éléments d'un objet et retourne une valeur en fonction du résultat. La dimension de la sortie d'un ifelse est la même que la dimension du premier argument qu'elle reçoit.

Ainsi, la fonction ifelse n'est pas une structure de contrôle.

Boucles

Les boucles ont pour but de répéter des instructions à plusieurs reprises, de les itérer. Parfois, le nombre d'itérations à effectuer est connu d'avance. D'autres fois, ce nombre n'est pas connu d'avance, car il dépend d'une condition à rencontrer.

Boucles for

Lorsque le nombre d'itérations à effectuer est prédéterminé, une boucle for est tout indiquée.

Écriture générale d'une boucle for :

```
for (valeur in ensemble) {
  instructions # exécutées à chaque itération de la boucle
}
```

Ce type de boucle débute par le mot clé for, suivi des éléments suivants, dans l'ordre.

- une parenthèse ouvrante;
- un nom quelconque, représenté par value dans la syntaxe générale;
- le mot-clé in :
- une instruction retournant un vecteur contenant l'ensemble des valeurs sur lesquelles itérer, représenté par ensemble dans la syntaxe générale;
- une parenthèse fermante.

Ensuite viennent la ou les instructions à répéter. S'il y a plus d'une instruction à répéter, les accolades sont nécessaires pour les encadrer. Dans ces instructions, l'objet nommé value dans la syntaxe générale intervient généralement.

La boucle effectuera autant de répétitions que la longueur du vecteur ensemble.

- Première itération : valeur contient ensemble [[1]].
- Deuxième itération : valeur contient ensemble[[2]].
- _ :
- Dernière itération : valeur contient ensemble [[length(ensemble)]].

Ainsi, de façon générale, pour les itérations i allant de 1 à length(ensemble), valeur contient ensemble[[i]].

Voici un exemple:

```
for (lettre in LETTERS){
  cat(lettre, " ")
}
```

A B C D E F G H I J K L M N O P Q R S T U V W X Y Z

Dans cet exemple, nous avons effectué 26 itérations, car length(LETTERS) = 26. À l'itération i, nous avons affiché le i^e élément du vecteur LETTERS, soit la i^e lettre de l'alphabet.

Nous aurions pu effectuer exactement la même boucle en itérant sur les entiers de 1 à 26 comme suit :

```
for (i in 1:length(LETTERS)){
  cat(LETTERS[[i]], " ")
}
```

A B C D E F G H I J K L M N O P Q R S T U V W X Y Z

Lorsque nous choisissons d'itérer sur les entiers allant de 1 au nombre total d'itérations à effectuer (disons n), il est commun d'utiliser le nom i pour l'objet changeant de valeur au fil des itérations et de créer le vecteur ensemble par l'instruction 1:n. Dans l'exemple précédent, n est remplacé par une instruction retournant

le nombre total d'itérations à effectuer, ici length(LETTERS). Nous aurions aussi pu utiliser l'instruction seq_along(LETTERS) au lieu de 1:length(LETTERS). Les deux instructions produisent exactement le même vecteur.

Voici un exemple de boucle for, utilisant le jeu de données attitude (provenant du package datasets)

```
str(attitude)
```

```
## 'data.frame':
                   30 obs. of 7 variables:
               : num 43 63 71 61 81 43 58 71 72 67 ...
##
   $ rating
   $ complaints: num 51 64 70 63 78 55 67 75 82 61 ...
   $ privileges: num
                      30 51 68 45 56 49 42 50 72 45 ...
   $ learning : num 39 54 69 47 66 44 56 55 67 47 ...
##
##
   $ raises
               : num 61 63 76 54 71 54 66 70 71 62 ...
   $ critical : num 92 73 86 84 83 49 68 66 83 80 ...
                      45 47 48 35 47 34 35 41 31 41 ...
##
   $ advance
               : num
```

Ce jeu de données contient 7 variables numériques. Ces données ont été recueillies dans le but d'étudier les variables influençant la cote (rating) reçue par 30 départements d'une grande organisation financière. Supposons que nous souhaitons réaliser 6 régressions linéaires simples sur ces données. Toutes les régressions auraient la même variable réponse, rating, et la variable explicative devrait être tour à tour une des autres variables du jeu de données.

L'instruction pour réaliser la régression simple avec la variable complaints par exemple, serait la suivante :

```
lm(rating ~ complaints, data = attitude)
```

```
# ou
lm(rating ~ ., data = attitude[, c(1, 2)])

##
## Call:
## lm(formula = rating ~ ., data = attitude[, c(1, 2)])
##
## Coefficients:
## (Intercept) complaints
## 14.3763 0.7546
```

Nous souhaitons maintenant insérer cette instruction dans une boucle permettant d'effectuer les 6 régressions simples.

```
modeles <- vector(length = 6, mode = "list")
for (i in 1:6) {
   modeles[[i]] <- lm(rating ~ ., data = attitude[, c(1, i + 1)])
}
modeles
## [[1]]
###</pre>
```

```
## Call:
## lm(formula = rating \sim ., data = attitude[, c(1, i + 1)])
##
## Coefficients:
##
   (Intercept)
                  privileges
       42.1087
                      0.4239
##
##
##
## [[3]]
##
## Call:
## lm(formula = rating \sim ., data = attitude[, c(1, i + 1)])
##
## Coefficients:
##
   (Intercept)
                    learning
##
       28.1741
                      0.6468
##
##
##
  [[4]]
##
## Call:
## lm(formula = rating \sim ., data = attitude[, c(1, i + 1)])
##
## Coefficients:
##
   (Intercept)
                      raises
##
       19.9778
                      0.6909
##
##
## [[5]]
##
## lm(formula = rating \sim ., data = attitude[, c(1, i + 1)])
##
## Coefficients:
##
   (Intercept)
                    critical
##
       50.2446
                      0.1924
##
##
## [[6]]
##
## Call:
## lm(formula = rating ~ ., data = attitude[, c(1, i + 1)])
## Coefficients:
##
   (Intercept)
                     advance
##
       56.7558
                      0.1835
```

Enregistrement des résultats dans une boucle

Une affectation de valeur à un endroit précis d'un objet (ex.: modeles[[i]] <- lm(...)) nécessite que l'objet existe préalablement. Ainsi, une boucle est souvent précédée par l'initialisation d'un objet dédié à contenir les résultats calculés dans la boucle. Dans l'exemple précédent, nous avons initialisé la liste modeles avant la boucle par l'instruction:

```
modeles <- vector(length = 6, mode = "list")</pre>
```

Remarquez que la fonction vector crée bien une liste ici, et non un vecteur, grâce à l'argument mode = "list".

Nous aurions pu choisir d'itérer sur les noms des variables explicatives plutôt que sur les entiers 1 à 6, comme suit :

```
modeles <- vector(length = 6, mode = "list")
names(modeles) <- names(attitude)[-1]

for (variable in names(modeles)) {
   modeles[[variable]] <- lm(rating ~ ., data = attitude[, c("rating", variable)])
}
modeles</pre>
```

Dans ce cas, nous avons préalablement nommé les éléments de la liste initialement vide. Ainsi, dans la boucle, nous pouvons référer à des éléments spécifiques de la liste modeles par leur nom plutôt que par leur indice.

Affichage de résultats dans une boucle

Voici une boucle très simple.

```
for (i in 1:5) {
   i
}
```

Si vous soumettez cette boucle, vous remarquerez qu'elle n'affiche rien. Pourtant, une instruction contenant uniquement le nom d'un objet affiche cet objet lorsque l'instruction est soumise dans la console.

```
i
```

[1] 5

Ce résultat ne se produit pas dans une boucle. Il faut utiliser les fonctions print ou cat pour qu'un résultat soit affiché dans la console pendant l'exécution d'une boucle.

```
for (i in 1:5) {
    print(i)
}

## [1] 1
## [1] 2
## [1] 3
## [1] 4
## [1] 5

for (i in 1:5) {
    cat(i)
}

## 12345

cat est utile pour faire afficher une trace des itérations.
```

```
for (i in 1:5) {
  cat("itération", i, "terminée\n")
}
```

```
## itération 1 terminée
## itération 2 terminée
```

```
## itération 3 terminée
## itération 4 terminée
## itération 5 terminée
```

Rappel : Le caractère \n représente un retour de chariot.

Boucles while ou repeat

Parfois, le nombre d'itérations dépend d'une condition à rencontrer, il n'est pas prédéterminé. Les boucles R while et repeat sont utiles dans cette situation.

Écriture générale d'une boucle while :

```
while (condition) {
  instructions # exécutées à chaque itération de la boucle
}
```

Écriture générale d'une boucle repeat :

```
repeat {
  instructions # exécutées à chaque itération de la boucle
  if (!condition) break
}
```

Un des intérêts d'une boucle repeat est de tester la condition après avoir exécuté les instructions et non avant comme dans une boucle while. Dans un boucle repeat, le mot-clé break doit être utilisé pour mettre fin aux itérations, sinon la boucle est infinie.

La condition doit encore une fois être une instruction qui retourne un seul TRUE ou un seul FALSE.

Dans les écritures générales ci-dessus, remarquez qu'il y a un opérateur logique de négation devant la condition dans la boucle repeat. C'est pour mettre en évidence le fait qu'une boucle while continue d'itérer tant que condition demeure TRUE. Pour une même condition, il faut donc faire arrêter la boucle repeat lorsque condition devient FALSE.

Voici un exemple.

Nous souhaitons simuler le lancer d'un dé jusqu'à l'obtention d'un 6 et compter le nombre de lancers.

```
resultat <- 1  # initialisation à un résultat quelconque, différent de 6

nbreLancers <- 0  # initialisation à 0 du nombre de lancer

while (resultat != 6) {  # tant que le résultat n'est pas égal à 6, répéter
  resultat <- sample(1:6, size = 1)  # simulation du lancer du dé
  nbreLancers <- nbreLancers + 1  # incrémentation du nombre de lancers
}

nbreLancers  # afficher le résultat final
```

La boucle while peut être remplacée par une boucle repeat avec un énoncé break comme suit.

```
nbreLancers <- 0
repeat {
   resultat <- sample(1:6, size = 1)
   nbreLancers <- nbreLancers + 1
   if (resultat == 6) break
}
nbreLancers</pre>
```

Ici, nous n'avons pas besoin d'initialiser resultat, car la condition est évaluée à la fin de la boucle, après avoir calculé resultat au moins une fois.

Remarque: Si les insctuctions dans une boucle while ou repeat n'ont aucun impact sur la condition et que celle-ci demeure toujours vraie, alors la boucle est infinie. Il est important de s'assurer que la condition devienne éventuellement fausse, afin que la boucle puisse s'arrêter.

Imbriquer des boucles

Dans l'exemple précédent, il serait intéressant de répéter l'expérience un grand nombre de fois et de calculer le nombre moyen de lancers requis pour obtenir un 6. Pour ce faire nous pourrions imbriquer la boucle while ou repeat dans une boucle for comme suit :

```
nbreRep <- 10000
nbreLancers <- rep(0, nbreRep) # ou vector(length = nbreRep, mode = "numeric")
for (i in 1:nbreRep) {
  resultat <- 1
  while (resultat != 6) {
    resultat <- sample(1:6, size = 1)
      nbreLancers[i] <- nbreLancers[i] + 1
  }
}
mean(nbreLancers)</pre>
```

```
## [1] 6.0604
```

Cet exemple montre une façon empirique d'estimer l'espérance d'une variable aléatoire géométrique de paramètre p=1/6. Plus grand est le nombre de répétitions, plus l'estimation est précise (convergence). En théorie, cette espérance vaut 1/p=6.

Il est simple d'imbriquer des boucles en R, peu importe leur type (for, while ou repeat). Cependant, nous verrons plus tard que plus l'imbrication possède de niveaux, plus le programme tend à être long à exécuter.

Mots-clés break et next

Deux mots-clés existent pour contrôler l'exécution des instructions à l'intérieur d'une boucle :

- break : pour terminer complètement l'exécution de la boucle (les itérations restantes ne sont pas effectuées).
- next : pour terminer immédiatement une itération (sans exécuter les instructions après le mot-clé next) et reprendre l'exécution de la boucle à la prochaine itération.

C'est deux mot-clés sont pratiquement toujours utilisés dans une structure if.

Le mot-clé break a déjà été illustré dans une boucle repeat. Notons cependant que nous pouvons l'utiliser dans une boucle de n'importe quel type.

Illustrons maintenant l'utilisation du mot-clé next. Reprenons l'exemple de l'affichage des lettres de l'alphabet. Supposons que nous souhaitons afficher seulement les consonnes.

```
for (lettre in LETTERS){
   if (lettre %in% c("A", "E", "I", "O", "U")) next
   cat(lettre, " ")
}
```

```
## B C D F G H J K L M N P Q R S T V W X Y Z
```

Dans ce programme, si la condition lettre %in% c("A", "E", "I", "O", "U") est rencontrée, nous passons à l'itération suivante de la boucle, sans soumettre l'instruction cat(lettre, " "). Le mot-clé next permet donc d'omettre l'exécution de certaines instructions.

En fait, le dernier programme fait la même chose que le programme suivant.

```
for (lettre in LETTERS){
   if (! lettre %in% c("A", "E", "I", "O", "U")){
     cat(lettre, " ")
   }
}
```

```
##BCDFGHJKLMNPQRSTVWXYZ
```

Ici, il n'y a plus de mot-clé next, mais l'instruction cat(lettre, " ") est dans le if plutôt qu'après le if.

Nous avons souvent constaté qu'il y a plusieurs façons de réaliser une même tâche en R. Cette remarque est aussi vraie pour les boucles.

Interruption de l'exécution d'une boucle

Il peut arriver que, par erreur, nous soumettions en R une boucle vraiment longue à rouler, possiblement infinie. En RStudio, l'exécution de n'importe quelle commande, incluant une boucle, peut être interrompue d'une des façons suivantes :

- la touche « Esc »,
- le bouton STOP en entête à droite de la sous-fenêtre de la console R,
- le menu « Session > Interrupt R ».

Éviter les boucles

Une des philosophies de base en programmation R est d'utiliser une boucle seulement si celle-ci est vraiment nécessaire pour réaliser la tâche à accomplir. Le fonctionnement vectoriel de plusieurs fonctions R, ainsi que les fonctions de la famille des apply, permettent bien souvent d'éviter l'utilisation d'une boucle.

Cette philosophie se base sur les faits suivants :

- Le calcul vectoriel est plus rapide que les boucles.
- Éviter les boucles produit habituellement un code plus court, donc plus rapide à écrire et aussi potentiellement plus facile à comprendre.

Calcul vectoriel versus boucle

Voici un exemple simple d'opération vectorielle. Supposons que nous avons le vecteur numérique x suivant.

```
x <- 1:10
```

Nous voulons élever au carré toutes les valeurs dans ce vecteur. En R, il est recommandé de réaliser cette tâche comme suit :

```
z <- x^2
z
```

```
## [1] 1 4 9 16 25 36 49 64 81 100
```

Dans bien des langages informatiques, il aura fallu faire une boucle, telle que celle-ci:

```
z <- vector(length = length(x), mode = "numeric")
for (i in 1:length(x)){
  z[i] <- x[i]^2
}
z</pre>
```

```
## [1] 1 4 9 16 25 36 49 64 81 100
```

Laquelle des deux solutions vous paraît la plus simple à comprendre?

Fonction de la famille des apply versus boucle

Voici un exemple simple d'utilisation d'une fonction de la famille des apply. Supposons que nous avons la matrice numérique mat suivante.

```
mat <- matrix(1:12, ncol = 3, nrow = 4)
mat
##
         [,1] [,2] [,3]
## [1,]
                 5
            1
            2
                 6
## [2,]
                      10
## [3,]
            3
                 7
                      11
## [4,]
                      12
```

Nous voulons calculer les sommes des valeurs par colonne. En R, il est recommandé de réaliser cette tâche comme suit :

```
sommesColonnes <- colSums(mat)
sommesColonnes</pre>
```

```
## [1] 10 26 42
```

La fonction colSums revient à un appel à la fonction apply optimisé pour la tâche spécifique du calcul de sommes en colonnes.

Dans bien des langages informatiques, il aura fallu faire une boucle, telle que celle-ci :

```
sommesColonnes <- vector(length = ncol(mat), mode = "numeric")
for (i in 1:ncol(mat)){
  sommesColonnes[i] <- sum(mat[, i])
}
sommesColonnes</pre>
```

```
## [1] 10 26 42
```

Il est plus rapide d'appeler la fonction colSums que d'écrire cette boucle.

Références

- Matloff, N. (2011). The Art of R Programming : A Tour of Statistical Software Design. No Starch Press. Chapitre 7.
- http://r4ds.had.co.nz/functions.html#conditional-execution
- http://r4ds.had.co.nz/iteration.html
- $\bullet \ \ https://www.datacamp.com/community/tutorials/tutorial-on-loops-in-r$
- Sections du tutoriel https://www.datamentor.io/r-programming:
 - Alternatives: https://www.datamentor.io/r-programming/if-else-statement
 - Boucles for: https://www.datamentor.io/r-programming/for-loop
 - Boucles while: https://www.datamentor.io/r-programming/while-loop
 - Boucles repeat: https://www.datamentor.io/r-programming/repeat-loop